

序列生成对抗网络在推荐系统中的应用

伍鑫¹, 黄勃^{1,2}, 方志军¹, 刘文竹¹

1. 上海工程技术大学 电子电气工程学院, 上海 201620

2. 江西省经济犯罪侦查与防控技术协同创新中心, 南昌 330000

摘要: 推荐系统旨在根据用户的历史行为数据发现该用户可能感兴趣的新项目, 并产生相应的推荐。当前大部分的推荐系统多根据用户的历史行为数据, 挖掘相似用户, 并从相似用户的历史数据中选出彼此历史数据中未出现的新项目; 或者根据用户感兴趣的历史项目匹配相似的新项目, 从而实现推荐。但这些推荐方式对原始数据有着较强的依赖关系, 且难以发觉不同项目之间隐含的序列关系。因此提出一种融合 Item2vec 和生成对抗网络 (Generative Adversarial Networks, GAN) 方法的推荐算法, 可以学习得到项目间难以表达的关系; 挖掘用户历史数据中的序列关系, 学习用户兴趣偏好的真实分布; 实现用户兴趣偏好的预测。实验发现该推荐算法具有较好的表现。

关键词: 推荐系统; 序列预测; Item2vec; 生成对抗网络 (GAN); 偏好特征

文献标志码: A **中图分类号:** TP391.1 **doi:** 10.3778/j.issn.1002-8331.1908-0428

伍鑫, 黄勃, 方志军, 等. 序列生成对抗网络在推荐系统中的应用. 计算机工程与应用, 2020, 56(23): 175-179.

WU Xin, HUANG Bo, FANG Zhijun, et al. Application of sequence generative adversarial network in recommendation system. Computer Engineering and Applications, 2020, 56(23): 175-179.

Application of Sequence Generative Adversarial Network in Recommendation System

WU Xin¹, HUANG Bo^{1,2}, FANG Zhijun¹, LIU Wenzhu¹

1. School of Electrical and Electronic Engineering, Shanghai University of Engineering and Technology, Shanghai 201620, China

2. Jiangxi Collaborative Innovation Center for Economic Crime Detection and Prevention and Control, Nanchang 330000, China

Abstract: The recommendation system is designed to discover new items that the user may be interested in based on the user's historical behavior data and generate corresponding recommendations. Most studies mine similar users according to the user's historical behavior data, and select items from the historical data of similar users, which is not appeared in the historical data of the target user, or match similar items according to user history to achieve recommendations. However, these recommendation methods have strong dependence on the original data, and it is difficult to detect the implicit sequence relationship between different items. Therefore, a recommendation algorithm which combines the Item2vec and Generative Adversarial Networks (GAN) is proposed in this paper, which can learn the relationship between different items. And this method can find the sequence relationship in the users' history data to learn the distribution of users' preference. Furthermore, the users' preference can be predicted. The experiment is performed and this method has great improvement.

Key words: recommendation system; sequence prediction; Item2vec; Generative Adversarial Networks (GAN); preference feature

1 引言

如今在信息爆炸的时代中, 充斥着大量的冗余信

息, 从而导致了信息的过载问题, 因此有效信息的获取变得十分困难。推荐系统作为一种信息过滤方法可有

基金项目: 国家自然科学基金青年基金项目 (No. 61603242); 江西省经济犯罪侦查与防控技术协同创新中心开放基金资助课题 (No. JXJZTCX-030)。

作者简介: 伍鑫 (1995—), 男, 硕士, 主要研究方向为推荐系统, E-mail: 1995wuxin@gmail.com; 黄勃 (1985—), 通信作者, 男, 上海工程技术大学电子电气工程学院讲师, 江西省经济犯罪侦查与防控技术协同创新中心特聘研究员, 研究方向为需求工程、软件工程、形式化方法、人工智能。

收稿日期: 2019-08-28 **修回日期:** 2019-11-29 **文章编号:** 1002-8331(2020)23-0175-05

CNKI 网络出版: 2019-12-09, <http://kns.cnki.net/kcms/detail/11.2127.TP.20191207.1508.018.html>

效缓解该问题。推荐系统对用户历史数据进行分析,挖掘用户兴趣偏好,在项目空间中确定用户喜欢的项目。传统的推荐系统通常以矩阵分解模型^[1]、协同过滤模型^[2]和基于上下文感知模型^[3]为主。传统的推荐模型多为静态的,没有考虑用户的兴趣变化以及不同项目之间隐含的序列关系,只能从全局层面实现推荐。然而这种推荐方式在实际应用中效果较差,难以产生满足用户需求的推荐。

此外,传统推荐系统通常只能处理相对较小的数据集。但如今大规模数据集的出现以及运算和硬件存储的进步,促使开发具有高精度和可扩展性的更强大推荐系统成为可能^[3-4]。

近些年,基于序列预测的推荐也得到了较好的发展,弥补了传统推荐模型中无法考虑不同项目间时序关系的问题。当前基于序列预测的模型多为递归神经网络(Recurrent Neural Networks, RNN)或基于RNN的变体等^[5-7]。上述序列预测模型一定程度上解决了序列预测问题,但在模拟用户行为轨迹方面仍然存在欠缺。为了更明确地模拟用户行为轨迹,本文提出了一种融合序列生成对抗网络(Sequence Generative Adversarial Networks, SeqGAN)^[8]的推荐算法,可以使用其生成模型来重现用户喜欢的项目序列,从而实现相应的推荐。同时在数据预处理方面引入 Item2vec^[9]对数据进行预处理,在降低数据维度的同时,还能保留数据之间良好的结构信息,此外使得相似项目的表示向量相似,解决了传统词嵌入方法中相似项目向量之间的关系不强的问题,同时也起到了降维、增加数据稠密度的作用。

2 相关工作

近年来,基于深度学习的推荐算法受到了很多关注。推荐系统可视为一种用户和项目之间的映射,深度学习作为一类常用的学习算法^[10],能够学习这种映射关系。常用深度模型如自动编码器^[11]、卷积神经网络(Convolutional Neural Networks, CNN)^[12]和RNN^[6-7]等均在推荐系统中取得了不错的表现。但以上方法在拟合用户兴趣动态偏好时,仍然存在较大偏差。为了更准确地模拟用户的典型行为,可以利用生成模型来生成用户的兴趣项目序列。例如,利用训练好的隐马尔可夫模型,根据用户当前喜欢的项目序列预测下一个项目,并将其推荐给用户^[13]。

Item2vec由微软亚洲研究院提出^[9],其主要思想是借鉴了Word2vec^[14],并采用SGNS(Skip-Gram+Negative Sampling)^[14]的方法来生成项目词向量。Item2vec在项目向量表示方面有着较强的优势,使得项目词嵌入后的词向量表示带有结构信息,即相似项目之间的距离较近,差异较大的项目之间距离较远。因此Item2vec在一定程度上保留了原始数据的结构信息,同时降低了数据维度,便于后期的训练学习以及推荐。

Goodfellow等人提出生成对抗网络(Generative Adversarial Networks, GAN)^[15],在图像生成^[16]到鲁棒控制^[17]等许多任务中的表现优于现有算法。这是因为GAN有效地利用深度学习的描述性和辨别力,训练具有高精度和可扩展性的生成模型。利用GAN在生成数据方面的良好特性,在推荐系统中利用GAN模拟用户的行为轨迹,从而较精确地预测每个用户的偏好^[18-19]。由于SeqGAN在文本生成方面取得了较好的成果,对序列特征有着较强的学习能力,因此本文将融合SeqGAN来挖掘推荐系统中项目之间的序列关系。

当前基于序列预测的模型中,在数据预处理以及降维阶段,常采用较为简单的one-hot向量表示项目,该表示方式存在向量稀疏且无法体现不同项目之间关系的问题。因此,本文提出Item2vec和SeqGAN相结合的推荐算法,选用Item2vec对项目进行预处理,从而得到带有结构信息的项目向量,然后采用SeqGAN来建立基于GAN的模型,学习用户的偏好,并向用户生成下一个项目的推荐。SeqGAN能够学习序列关系,为推荐任务提供了一个有效的框架。因此本文对SeqGAN做了适当的改进,使其适用于推荐任务。为了验证模型的有效性,在Netflix Prize Contest数据集和Movielens数据集上进行了实验。实验结果表明,本文提出的模型优于基线算法。

3 模型描述

模型首先需要将电影项目映射成相应的词向量,再根据用户历史记录的时间戳属性,构建不同的序列信息。如图1中的Embedding部分所示。

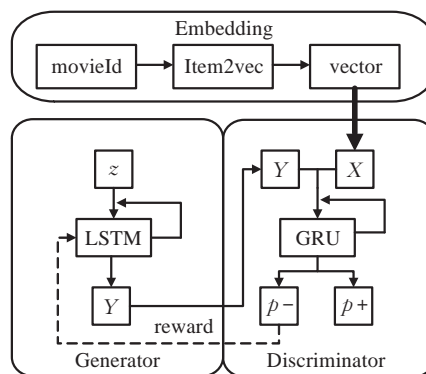


图1 模型总体框架

本文改进的SeqGAN,生成器通过噪声 z 产生虚拟的用户观看电影的序列信息 $Y = \{y_1, y_2, \dots, y_t\}$,如图1中Generator部分所示。将生成器生成的项目序列信息 Y 和由Item2vec根据真实信息产生的真实项目词向量序列信息 $X = \{x_1, x_2, \dots, x_t\}$ 分别传入鉴别器Discriminator中,输出传入项目序列 X 和 Y 为真实序列的概率值,其中 p_- 表示生成器产生的序列 Y 鉴别为真实序列的概率值, p_+ 表示真实序列 X 鉴别为真实序列的概率值。然后将 p_- 作为生成器获得的奖励,指导生成器迭

代更新,促使生成器尽可能地发掘用户序列信息的真实分布特征。具体的对抗训练过程如图1所示。

3.1 数据预处理

首先根据数据集的时间属性对无序的用户数据进行处理。传统的词嵌入方法如one-hot存在向量稀疏且难以表示电影和电影之间的关系等问题;有研究发现RNN以及RNN的变体在数据密度较高时能发挥较好的性能^[10],本模型的生成器采用LSTM(Long Short-Term Memory)构成,鉴别器采用GRU(Gated Recurrent Unit)构成,均为RNN的变体;采用Item2vec方法,该方法可以学习电影项目在低维空间的词向量表示,增加数据的密度,同时可以学习不同电影项目之间的关系。

假设所有用户观看的电影的历史记录被定义为一个语料库,同时将某一个用户 u 观看的一系列电影记录视为一个小的电影集合,用 W_u 表示。所有的电影项目视为词汇集合,用 $S(W_u \in S)$ 表示。通过学习所有用户历史记录中电影间的共现关系,获得该电影项目的词向量表示。具体的目标函数如下:

$$L = \frac{1}{M} \sum_{i=1}^M \sum_{j=1}^M \lg P(W_i | W_j) \quad (1)$$

$$P(W_i | W_j) = \sigma(u_i^T v_j) \prod_{k=1}^N \sigma(-u_i^T v_k) \quad (2)$$

其中, $\sigma(x) = 1/(1 + \exp(-x))$, $u \in W_i$, $v \in W_j$, N 为对于每个正样本负采样的个数。

假定出现在用户历史记录中的电影项目均为有效项目,因此用户在选择某个电影项目时,该电影项目即代表该用户此时的兴趣趋向。即可将某一时刻用户所选的电影项目的词向量表示作为该用户此时的兴趣特征向量。

3.2 模型生成器

LSTM比较适用于序列预测问题,能够挖掘用户兴趣特性的分布特点。因此,采用LSTM来构建SeqGAN中的生成器 G_θ (θ 为参数)。此外,为了同时处理用户的时间静态偏好和动态偏好,本文在LSTM单元的输入门(i_t)使用Leaky RELU激活函数,如式(3)所示。Leaky RELU可以很好地控制输入门信息的写入和丢弃,使模型对于时间静态偏好的用户关注其过去的行为,对于动态偏好的用户自动为其建模并完成预测。

为促使生成器挖掘用户兴趣的真实分布,在生成器中输入噪声 z 取代真实的序列数据。此方法可避免生成器过度依赖原始数据的问题,防止模型的过拟合。借助鉴别器的监督训练,实现对抗学习,从而挖掘用户的真实兴趣特征模型。

在LSTM单元通过噪声 z 为其产生一个初始的隐状态 h_1^g ,如式(4)所示。其中 y_t 表示生成的兴趣特征,生成过程如式(6)所示。生成器 $G_\theta = \{y_1, y_2, \dots, y_T\}$ 。

$$i_t = \text{RELU}(W_i \cdot [h_{t-1}^g, y_t] + b_i) \quad (3)$$

$$h_1^g = \text{LSTM}(z, h_0^g) \quad (4)$$

$$h_t^g = \text{LSTM}(y_t, h_{t-1}^g) \quad (5)$$

$$y_t = W \cdot h_t^g + b \quad (6)$$

3.3 模型鉴别器

在GAN中,为了更好地训练生成器,促使生成器生成更真实的数据,需要鉴别器辅助生成器的训练过程。GRU在文本分类任务中显示出较好的效果,因此选择GRU作为鉴别器 D_ϕ (ϕ 是参数)来辅助生成器 G_θ 的迭代更新过程。 $D_\phi(Y_{1:T})$ 表示序列 $Y_{1:T} = \{y_1, y_2, \dots, y_T\}$ 为真实序列数据可能性的概率。真实的用户电影序列数据为正例,生成模型 G_θ 生成的数据为负例,通过正例和负例对判别模型 D_ϕ 进行训练。

$$h_t^d = \text{GRU}(y_t, h_{t-1}^d) \quad (7)$$

$$p(y_t | y_1, y_2, \dots, y_{t-1}) = \sigma(W h_t^d + b) \quad (8)$$

$$D_\phi(Y_{1:T}) = \frac{1}{T} \sum_{i=1}^T p(y_i) \quad (9)$$

鉴别器中最终以sigmoid函数评估序列中各个节点为真实数据的可能性,如式(8),并累积该估计值,取其平均值作为该序列为真实序列的可能性,如式(9)。

3.4 策略梯度

为了更好地辅助生成对抗训练,本文采用强化学习算法学习动作价值函数 $Q_{D_\phi}^{G_\theta}(s, a)$,即从状态 s 开始采取动作 a 可获得的预期奖励。将鉴别器 D_ϕ 的实际估计概率视为实际得到的奖励,使用鉴别器 D_ϕ 作为奖励函数,并动态迭代更新奖励函数,以进一步优化生成器。

$$Q_{D_\phi}^{G_\theta}(a = y_T, s = Y_{1:T-1}) = D_\phi(Y_{1:T}) \quad (10)$$

一旦获得一组更真实的生成预测序列,该模型将重新训练鉴别器,模型描述如下:

$$\min_{\phi} (-\mathbb{E}_{X \sim p_{\text{data}}} [\lg D_\phi(X)] - \mathbb{E}_{Y \sim G_\theta} [\lg(1 - D_\phi(Y))]) \quad (11)$$

生成器模型 G_θ 的目标是根据起始状态 s_0 生成序列,并最大化其预期的最终奖励,其目标函数 $J(\theta)$ 如方程(13)所示:

$$J(\theta) = \mathbb{E}[R_T | s_0, \theta] = \sum_{y_1 \in y} G_\theta(y_1 | s_0) \cdot Q_{D_\phi}^{G_\theta}(s_0, y_1) \quad (12)$$

其中, R_T 是生成的完整序列的奖励。

在模型训练过程中,每次获得新的鉴别器模型时,都会对生成器进行更新。本文基于策略梯度的优化方式依赖于最大化长期奖励。对目标函数 $J(\theta)$ 求梯度:

$$\nabla_{\theta} J(\theta) = \sum_{t=1}^T \mathbb{E}_{Y_{1:t-1} \sim G_\theta} \left[\sum_{y_t \in y} \nabla_{\theta} G_\theta(y_t | Y_{1:t-1}) \cdot Q_{D_\phi}^{G_\theta}(Y_{1:t-1}, y_t) \right] \quad (13)$$

其中, y_t 是从 G_θ 生成的预测。由于期望 \mathbb{E} 可以通过采样方法近似,然后将生成器的参数更新为:

$$\theta \leftarrow \theta + \alpha_h \nabla_{\theta} J(\theta) \quad (14)$$

采用Adam^[16]和RMSprop^[18]等自适应学习率的优化算法, $\alpha_h \in R_+$ 表示第 h 步的学习率。此外,在真实的数据

表1 基于Movielens-20M数据集对比分析($n=10$)

算法	MAP	MRR
KNN	0.02	0.05
BPR-MF	0.02	0.03
MC	0.07	0.15
RNN	0.10	0.24
SeqGAN	0.17	0.29

表2 基于Netflix数据集对比分析($n=10$)

算法	MAP	MRR
KNN	0.09	0.04
BPR-MF	0.11	0.03
MC	0.10	0.12
RNN	0.13	0.21
SeqGAN	0.15	0.30

BPR-MF这类基线模型不具备序列预测的特性;而本文模型能够发掘用户潜在的兴趣偏好变化轨迹,根据当前兴趣偏好进行预测。同时Item2vec方法在降低稀疏性的同时,让同类型的电影在向量表示上也具备了一定的相似性,对后期的序列预测,以及挖掘用户潜在的兴趣模型提供了有力条件。此外,相较于直接利用RNN训练的网络模型,采用对抗训练的方式,可以有效降低模型的过拟合,更利于对用户的兴趣模型进行精确建模。

6 结束语

本文讨论了Item2vec和SeqGAN在推荐系统中的具体实现。将两者相结合,改进传入SeqGAN网络的项目向量表示,在降低向量表示维度的同时,让项目的结构信息融入其向量表示中。同时改进SeqGAN网络结构,使其更适合推荐系统的应用场景。本文模型旨在对基于时序关系的用户和项目潜在特征精确建模,从而提高推荐系统的准确性。

实验结果表明,SeqGAN在两个不同的数据集中表现均优于基线模型。未来工作集中于进一步研究和改进SeqGAN的性能,以及对LSTM进行改进的可行性和影响进行深入研究,以便更精准地对用户兴趣建模。

参考文献:

- [1] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems[J]. Computer, 2009(8): 30-37.
- [2] Zhang R, Liu Q, Wei J X. Collaborative filtering for recommender systems[C]//2014 2nd International Conference on Advanced Cloud and Big Data, 2014: 301-308.
- [3] Covington P, Adams J, Sargin E. Deep neural networks for Youtube recommendations[C]//10th ACM Conference on Recommender Systems, 2016: 191-198.
- [4] Haarnoja T, Tang H, Abbeel P, et al. Reinforcement learning with deep energy-based policies[C]//34th International Conference on Machine Learning, 2017: 1352-1361.
- [5] Tang J, Wang K. Personalized top-n sequential recommendation via convolutional sequence embedding[C]//11th ACM International Conference on Web Search and Data Mining, 2018: 565-573.
- [6] Devooght R, Bersini H. Long and short-term recommendations with recurrent neural networks[C]//25th Conference on User Modeling, Adaptation and Personalization, 2017: 13-21.
- [7] Chu Y, Huang F, Wang H, et al. Short-term recommendation with recurrent neural networks[C]//2017 IEEE International Conference on Mechatronics and Automation, 2017: 927-932.
- [8] Yu L, Zhang W, Wang J, et al. SeqGAN: sequence generative adversarial nets with policy gradient[C]//31st AAAI Conference on Artificial Intelligence, 2017.
- [9] Barkan O, Koenigstein N. Item2vec: neural item embedding for collaborative filtering[C]//2016 IEEE 26th International Workshop on Machine Learning for Signal Processing, 2016: 1-6.
- [10] Zhang S, Yao L, Sun A, et al. Deep learning based recommender system: a survey and new perspectives[J]. ACM Computing Surveys, 2019, 52(1): 5.
- [11] Kuchaiev O, Ginsburg B. Training deep autoencoders for collaborative filtering[J]. arXiv: 1708.01715, 2017.
- [12] Gong Y, Zhang Q. Hashtag recommendation using attention-based convolutional neural network[C]//25th International Joint Conference on Artificial Intelligence, 2016: 2782-2788.
- [13] Sahoo N, Singh P V, Mukhopadhyay T. A hidden Markov model for collaborative filtering[J]. Management Information Systems Quarterly, 2012, 36(4): 1329-1356.
- [14] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality[C]//Advances in Neural Information Processing Systems, 2013: 3111-3119.
- [15] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems, 2014: 2672-2680.
- [16] Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv: 1511.06434, 2015.
- [17] Ho J, Ermon S. Generative adversarial imitation learning[C]//Advances in Neural Information Processing Systems, 2016: 4565-4573.
- [18] Wang J, Yu L, Zhang W, et al. IRGAN: a minimax game for unifying generative and discriminative information retrieval models[C]//40th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2017: 515-524.
- [19] Zhao W, Wang B, Ye J, et al. PLASTIC: prioritize long and short-term information in top-n recommendation using adversarial training[C]//27th International Joint Conference on Artificial Intelligence, 2018: 3676-3682.